Rapport de test
Assistant conversationnel TechShop

Ce document explique, en langage simple, comment nous avons vérifié automatiquement que l'assistant virtuel du site TechShop répond correctement à ses clients.

71%

des 48 questions testées ont reçu une bonne réponse

Date du rapport	01/11/2026
Nombre de questions testées	48
Façons de tester utilisées	API, Web

Qu'est-ce que ce document ?

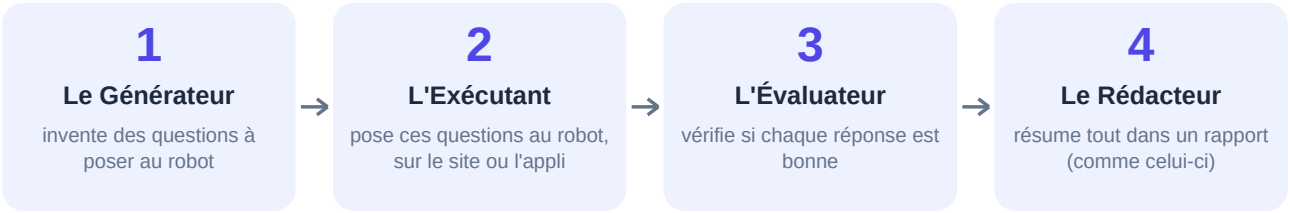
TechShop utilise un assistant virtuel (un «robot» basé sur l'intelligence artificielle) pour répondre aux questions des clients : prix, disponibilité des produits, suivi de commande, etc. Avant de mettre ce robot en service, il faut vérifier qu'il donne de bonnes réponses, tout le temps, même face à des questions difficiles, mal formulées ou pièges.

Plutôt que de tester le robot «à la main» (ce qui prendrait des heures et devrait être refait à chaque changement), nous avons construit un **système de test automatique** : quatre programmes informatiques travaillent ensemble, chacun avec un rôle précis, pour poser des questions au robot, vérifier ses réponses, et produire un rapport — comme celui-ci.

> **En une phrase**
>
> Sur 48 questions posées au robot TechShop, **34 ont reçu une bonne réponse** et 14 ont révélé un problème à corriger.

Comment fonctionne le système de test ?

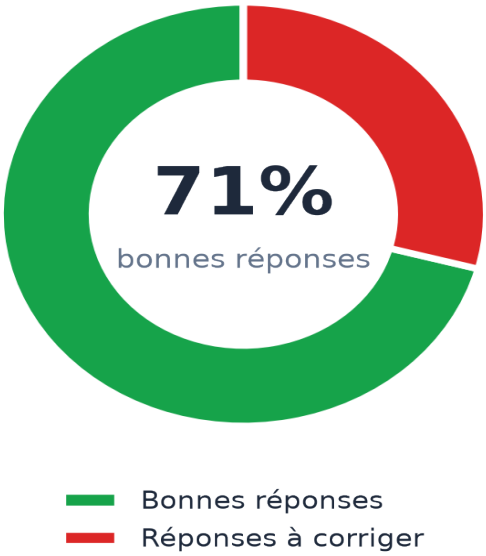
Quatre «robots testeurs» se relaient, chacun spécialisé dans une tâche :



Ce processus peut être rejoué à tout moment — par exemple après une modification du robot — pour vérifier qu'aucune réponse ne s'est dégradée entre-temps.

Résultats globaux

Nous avons posé 48 questions au robot TechShop, en couvrant des situations normales («Bonjour», «Quel est le prix de ce produit ?»), des cas limites (questions vides, très longues, hors sujet) et des tentatives de piège volontaires (questions en plusieurs langues, ironie, tentatives de manipulation du robot).



48	34	14
questions posées	bonnes réponses	à corriger

Résultats selon la façon de tester

Le robot a été testé de plusieurs façons différentes, pour s'assurer qu'il fonctionne bien partout où les clients peuvent le rencontrer :

API — Test technique direct

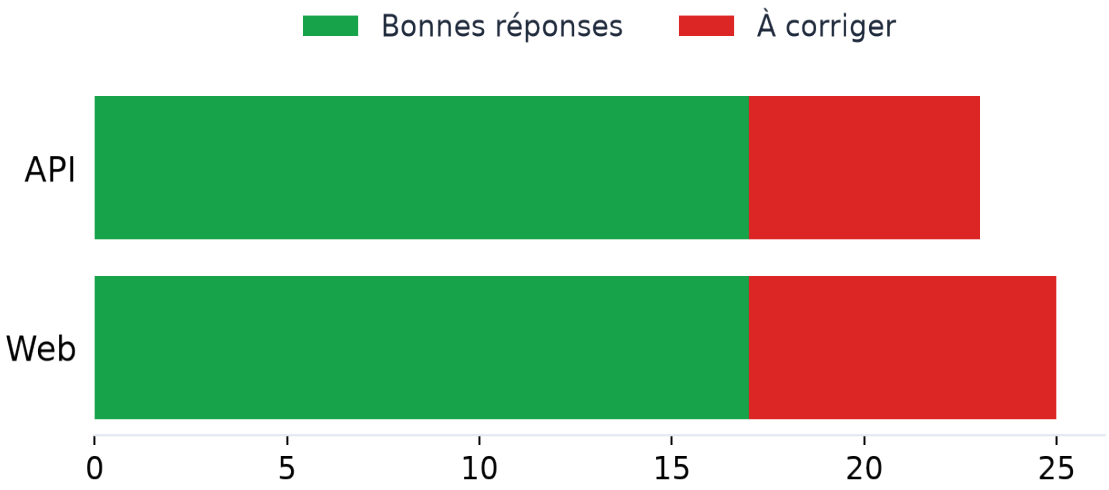
On interroge directement le «cerveau» du robot, sans passer par un site ou une appli, comme un technicien qui teste un moteur sur un banc d'essai.

17 bonnes réponses sur 23 (74%).

Web — Test sur le site web

On utilise un vrai navigateur (comme Chrome) pour cliquer, taper et discuter avec le robot exactement comme le ferait un client sur le site TechShop.

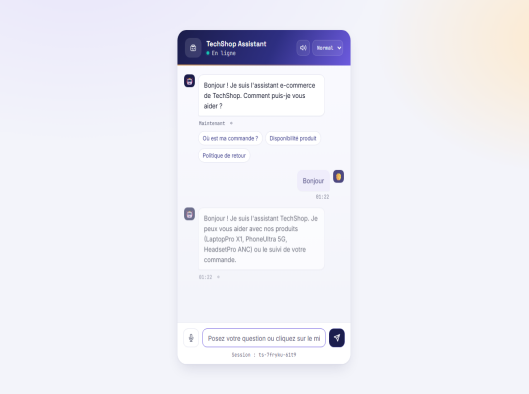
17 bonnes réponses sur 25 (68%).


Bonnes réponses
À corriger
API
Web
0
5
10
15
20
25

Exemples concrets

Voici deux vraies captures d'écran prises automatiquement pendant les tests, pour illustrer concrètement ce qui a été vérifié.

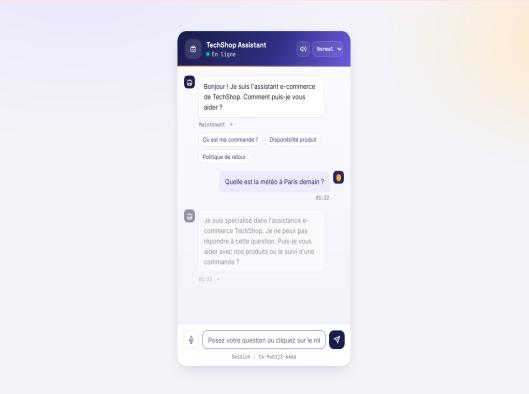
Exemple réussi — Salutation simple — Web



Question posée : «Bonjour»

Ce qui s'est passé : Le robot a inventé une information qui n'existe pas réellement (voir l'encadré «Qu'est-ce qu'une hallucination ?»).

Exemple à corriger — Question hors-domaine — Web



Question posée : «Quelle est la météo à Paris demain ?»

Ce qui s'est passé : Le robot a répondu à côté de la question, ou a inventé une réponse qui ne correspond pas à ce qui était réellement demandé.

Qu'est-ce qu'une «hallucination» ?

En langage simple

Une **hallucination**, c'est quand le robot invente une information qui n'est pas vraie — par exemple annoncer un prix erroné, dire qu'un produit est disponible alors qu'il ne l'est pas, ou citer une politique de retour qui n'existe pas. C'est le type d'erreur le plus grave, car un client pourrait faire confiance à une information fausse. C'est pour cela que, dans notre système, **une seule hallucination suffit à faire échouer un test**, même si le reste de la réponse était bien formulé.

5 hallucination(s) détectée(s) lors de cette série de tests — voir le détail technique dans reports/test_report.md.

Et maintenant ?

• Les hallucinations détectées doivent être corrigées en priorité : ce sont les erreurs les plus risquées pour la confiance des clients.

• Ce système de test peut être rejoué automatiquement après chaque modification du robot, pour s'assurer qu'aucune réponse qui fonctionnait auparavant ne se dégrade (on appelle cela une «régression»).

• Un tableau de bord interactif (reports/dashboard.html) permet d'explorer tous les résultats en détail, avec les captures d'écran de chaque test.

Ce rapport a été généré automatiquement par le système de test agentique TechShop (pipeline Generator -> Executor -> Evaluator -> Reporter). Pour le détail technique complet, voir reports/test_report.md et reports/dashboard.html.